Modelagem da felicidade de residentes dos países

CW03 - Análise de Regressão

AUTORES
Milena Paz Freitas - 202165109AD
Bernardo Ferreira Almeida - 202365602D

DATA DE PUBLICAÇÃO
22 de abril de 2026

Neste trabalho, com fins pedagógicos, foi explorado e ajustado um modelo para pontuação de satisfação(felicidade) em residir em certos países. A partir dos dados, foi realizada uma análise exploratória, definição do modelo e avaliação de contribuição de cada uma das covariáveis.

Palavras-Chave:

Regressão Múltipla; Qualidade de vida; Teste de Hipóteses.

Introdução

Desejamos identificar uma relação entre a pontuação de 1 a 10 atribuída à felicidade da população de determinados países (Helliwell et al. (2022)) e outras variáveis indicativas de qualidade de vida. Para esse fim, foi utilizada a base de dados de *World Happiness*, onde se encontram essas pontuações obtidas para cada país, correspondendo à média de três anos de cerca de 1.000 entrevistas anuais. O modelo que iremos ajustar, inicialmente, será do tipo:

$$Score \sim GDP + Social + Healthy + Freedom + Generosity + Corruption.$$

Análise Exploratória dos Dados

Com o intuito de identificar relação entre a pontuação da nação e outras covariáveis indicadoras de qualidade de vida, realiza-se uma análise exploratória. Foi feita análise descritiva dos dados, obtendo a seguinte tabela:

	Média	Mediana	Q1	Q3	Mínimo	Máximo	CV
GDP	1.4104294	1.4451341	1.0955776	1.7850874	0.0000	2.2093954	29.89548
Social	0.9058340	0.9577989	0.7321140	1.1146581	0.0000	1.3199135	30.92437
Healthy	0.5861465	0.6214446	0.4629530	0.7200648	0.0000	0.9418287	30.08664
Freedom	0.5172254	0.5436333	0.4405062	0.6257626	0.0000	0.7400386	28.19532
Generosity	0.1473721	0.1324174	0.0887231	0.1975543	0.0000	0.4679258	56.15920
Corruption	0.1547576	0.1194594	0.0680874	0.1982132	0.0000	0.5868281	82.40100
Score	5.5535753	5.5687001	4.8885499	6.3050251	2.4038	7.8210001	19.56963

Aqui é especialmente fácil observar que nenhuma nação obteve pontuação acima de 8 pontos. Além desses resultados, temos como explorar os dados visualmente. Por exemplo, uma matriz de gráficos:

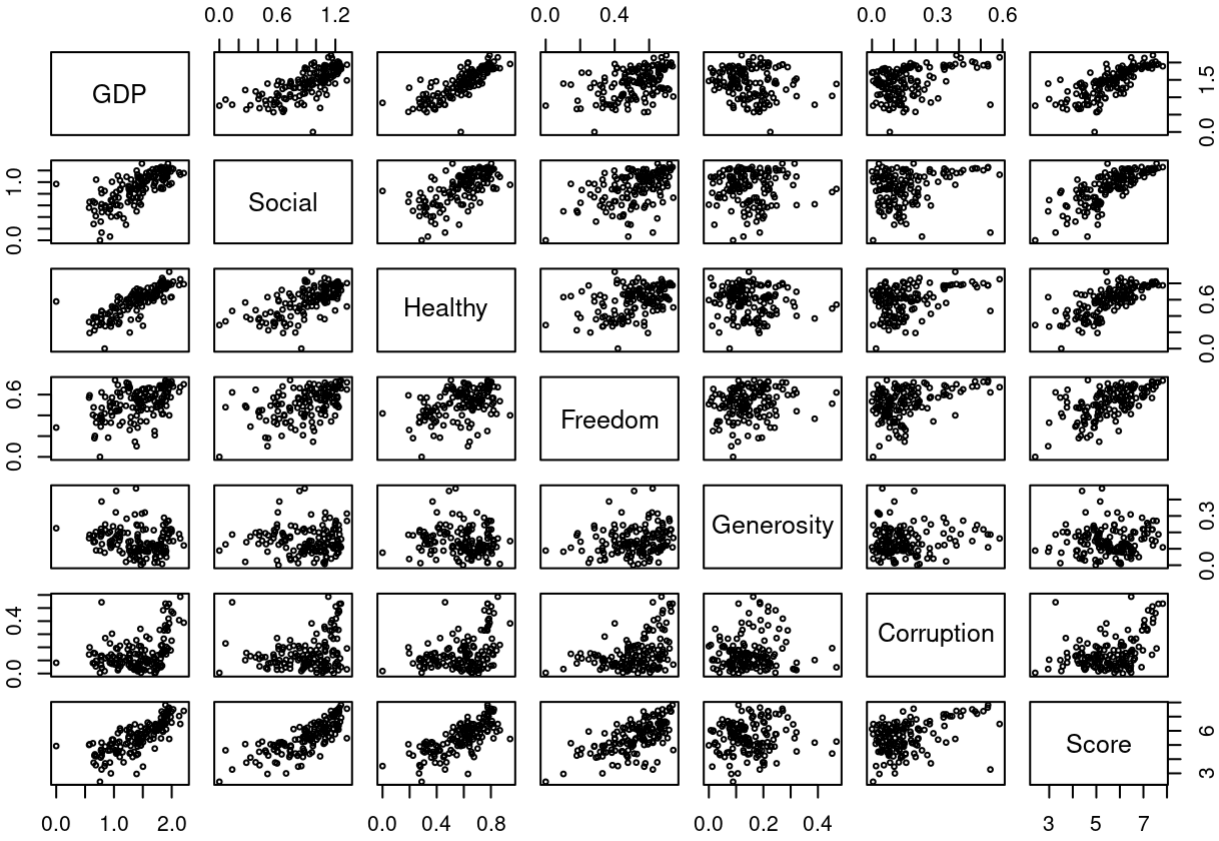

Matriz de Gráficos de Dispersão

É interessante observar a linha/coluna de Score em relação às outras variáveis, já que é a pontuação que desejamos explicar por meio delas.

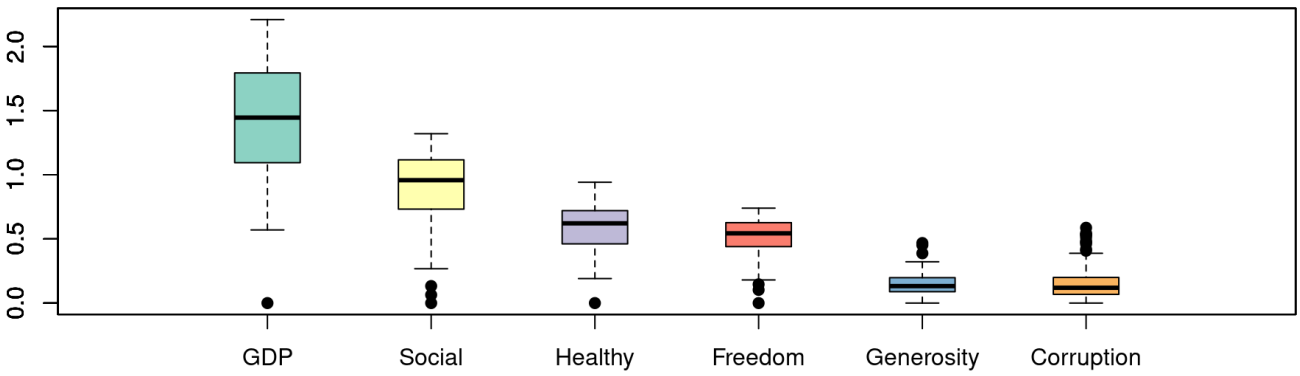

Boxplot das variáveis explicativas

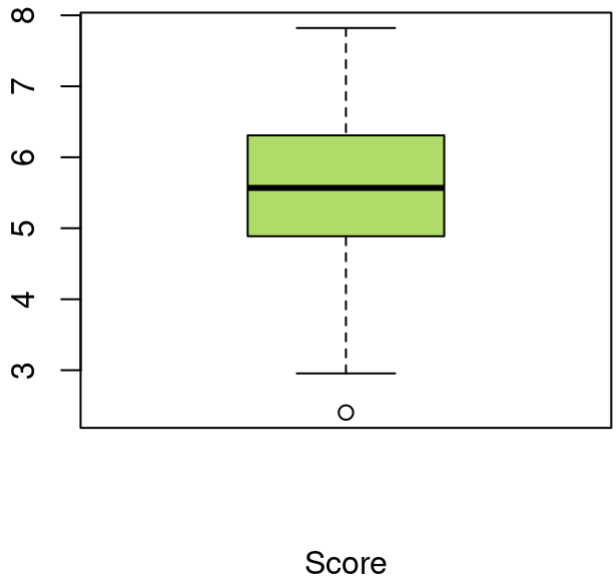

Boxplot da pontuação

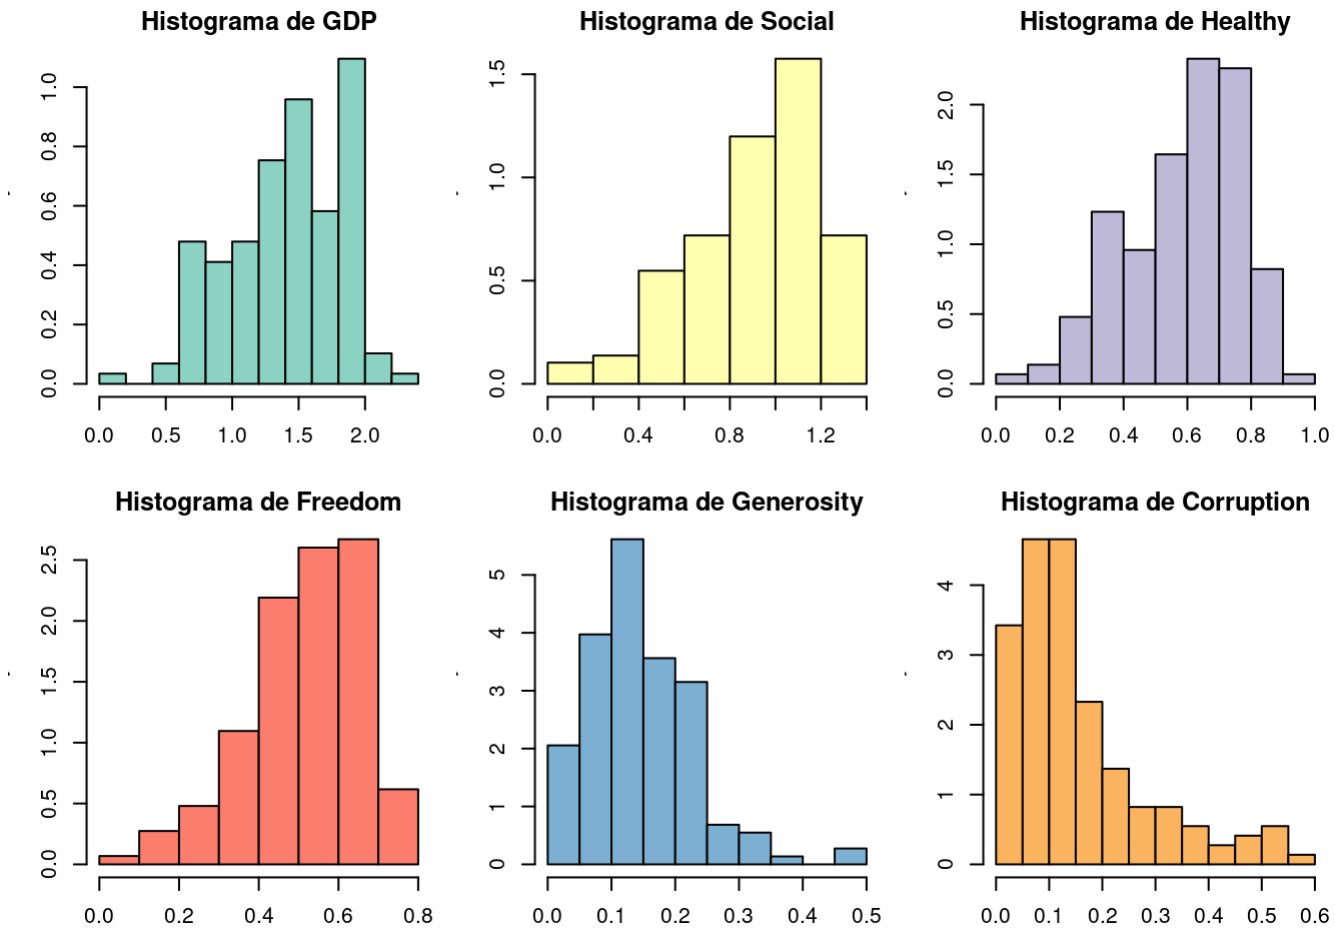

Histogramas de densidade das covariáveis

Modelo de regressão

Os coeficientes encontrados foram:

(Intercept)	GDP	Social	Healthy	Freedom	Generosity	Corruption
1.668027	0.5503029	1.409365	1.274971	1.604476	0.9662858	0.7310468

A interpretação para este modelo é como segue: temos 7 parâmetros, o intercepto dita qual o valor médio previsto para a variável resposta(Score) caso todas as outras variáveis independentes sejam 0. Os outros números ditam o quanto a variável resposta aumenta em média para cada unidade de aumento da variável pergunta associada àquele parâmetro (assumindo que as outras variáveis permaneçam constantes).

Note que todos eles são positivos, ou seja, o aumento de qualquer uma dessas variáveis causará, em média, um aumento no score de felicidade. O mesmo vale para o caso de diminuição de qualquer uma dessas variáveis, haverá um decrescimento médio na variável resposta.

Freeedom, Social e Healthy estarem entre os maiores coeficientes significa que esses são os que mais influenciariam positivamente na felicidade geral caso aumentassem. Enquanto GDP, por exemplo, não afetaria no aumento tão bem quanto algum desses 3.

Teste de hipóteses

Com valor de significância $\alpha = 0.05$ fizemos um teste bilateral que busca testar a hipótese de que algum respectivo β não é igual a 0, ou seja, testar se ele traz significância para o modelo, já que se ele fosse 0, a variável pergunta associada a ele não teria efeito algum no resultado final e o modelo poderia ser reduzido.

Ou seja, nossas hipóteses são, para cada β_i no modelo:

$$\begin{cases} \mathcal{H}_0 & \beta_i = 0 \\ \mathcal{A} & \beta_i \neq 0 \end{cases}$$

As estatisticas encontradas foram as seguintes:

β_0	β_1	β_2	β_3	β_4	β_5	β_6
15.368	5.026	11.011	5.468	8.092	3.219	3.492

A regiao de rejeição para as hipóteses:

```
[1]      -Inf -1.977178
```

```
[1] 1.977178      Inf
```

Para todos os coeficientes calculados, a hipótese nula foi rejeitada, então, com 95% de confiabilidade, nosso modelo é inteiramente significativo, nenhuma variável inclusa tem efeito negligível.

Conclusão

Ao tentarmos modelar a felicidade média de cada país, colocamos em um modelo linear da forma:

$$Y = \beta_0 + \beta_1 GDP + \beta_2 Social + \beta_3 Healthy + \beta_4 Freedom + \beta_5 Generosity + \beta_6 Corruption + \epsilon,$$

$$\epsilon \sim N(0, \sigma^2)$$

Ao estimarmos os coeficientes, encontramos que todos são positivos, o que indica que o aumento de qualquer uma das variáveis cria um aumento médio na felicidade total.

Além de serem todos positivos, eles ficam todos entre 0.5 e 2, que, ao considerar a escala da variável resposta ser de 0 a 10, mostra que as variáveis contribuem e afetam relativamente bem no resultado.

Porém, elas serem positivas não é o suficiente para assumir que o modelo é significativo. Então, em seguida foi feito um teste de hipótese para cada variável, com o intuito de verificar sua contribuição para o modelo no geral, foi encontrado que todas as hipóteses nulas foram rejeitadas, e que assim todas as variáveis contribuíam para o modelo.

Referências

Helliwell, J. F., R. Layard, J. D. Sachs, J.-E. De Neve, L. B. Aknin, and S. Wang (2022). **World Happiness Report 2022**. New York: Sustainable Development Solutions.